

Proyecto Final:

Predicción del éxito académico en educación superior

1. Descripción del conjunto de datos

Vas a trabajar con un conjunto de datos sobre abandono, permanencia y éxito académico de estudiantes de educación superior. El objetivo general del proyecto será construir modelos que permitan comprender mejor los factores asociados a la trayectoria académica del alumnado y anticipar tanto su situación académica futura como su rendimiento.

El dataset contiene información demográfica, socioeconómica, administrativa y académica de los estudiantes en el momento de acceso a la universidad, así como variables relacionadas con su desempeño en el primer y segundo semestre. Entre otras, encontrarás variables relativas a la vía de acceso, notas previas, situación económica, becas, deudas, situación de matrícula y resultados académicos en distintas unidades curriculares.

La variable objetivo del conjunto de datos distingue tres situaciones posibles del estudiante:

- **Abandono:** el estudiante abandonó los estudios.
- **Matriculado:** el estudiante continuaba matriculado, es decir, seguía cursando la titulación pero todavía no la había finalizado.
- **Graduado:** el estudiante completó sus estudios.

Además, el dataset contiene variables numéricas de rendimiento académico para primer y segundo semestre, incluyendo número de asignaturas matriculadas, evaluadas, aprobadas y la calificación media obtenida.

Para facilitar la comprensión del problema, a continuación se resume la información del dataset por bloques de variables:

Bloques de variables disponibles

- **Variables demográficas y personales.** Incluyen, entre otras, la edad de acceso, el género, la nacionalidad y si el estudiante es desplazado. Estas variables permiten caracterizar el perfil básico del alumnado.
- **Variables de acceso y contexto académico previo.** Recogen información sobre la vía de acceso a la universidad, el tipo de titulación o curso previo, la nota de acceso, la nota de la cualificación previa, el orden de preferencia de la titulación y la ocupación o nivel formativo de los progenitores. Este bloque resulta especialmente relevante para estudiar el rendimiento esperado antes del comienzo de los estudios universitarios.
- **Variables socioeconómicas y administrativas.** Incluyen información sobre si el estudiante es becario, si tiene pagos al día, si es deudor, si recibe apoyo especial o si su situación de matrícula presenta incidencias administrativas. Estas variables pueden ser relevantes para comprender el riesgo de abandono y las diferencias de trayectoria académica.

- **Variables macroeconómicas y de entorno.** El dataset incorpora también algunas variables contextuales agregadas, como tasa de desempleo, inflación o PIB. Aunque no describen al estudiante de forma individual, pueden utilizarse para analizar si el contexto económico general se asocia con determinadas trayectorias académicas.
- **Variables de rendimiento del primer semestre.** Se dispone de información agregada sobre el número de unidades curriculares matriculadas, evaluadas, aprobadas, la calificación media obtenida y el número de asignaturas sin evaluación en el primer semestre. Este bloque es muy útil para estudiar el desempeño inicial del estudiante y su relación con el éxito posterior.
- **Variables de rendimiento del segundo semestre.** De forma análoga al primer semestre, se incluyen variables agregadas del segundo semestre: asignaturas matriculadas, evaluadas, aprobadas, nota media y número de unidades sin evaluación. Estas variables son especialmente informativas, pero deben tratarse con cuidado cuando se formulen tareas predictivas para evitar fuga de información.

En el fichero de datos que se te proporciona, las columnas aparecen renombradas en español siguiendo una convención de nombres homogénea y, además, las variables categóricas han sido traducidas a etiquetas legibles. En particular, aquellas variables categóricas que originalmente aparecían codificadas mediante números (por ejemplo, ocupación, nacionalidad, vía de acceso o cualificación previa) se han transformado a valores de tipo texto con el significado correspondiente de cada categoría. A modo orientativo, encontrarás variables como `edad_al_matricularse`, `nota_de_admision`, `becario`, `pagos_al_dia`, `ocupacion_madre`, `nacionalidad`, `unidades_curriculares_1er_semestre_aprobadas` o `unidades_curriculares_2do_semestre_calificacion`. Revisa cuidadosamente la documentación del dataset y la semántica de cada variable antes de incorporarla a tus modelos.

2. Objetivo de la tarea

Queremos que desarrolles un proyecto con **tres tareas complementarias** sobre este conjunto de datos: una tarea de clasificación, una tarea de regresión y una tarea de aprendizaje no supervisado.

2.1. Tarea 1: Clasificación

La primera tarea consistirá en construir uno o varios modelos de **clasificación supervisada** para predecir la variable objetivo original del dataset, es decir, la situación final del estudiante entre las clases **Abandono**, **Matriculado** y **Graduado**.

Esta tarea te permitirá analizar hasta qué punto es posible anticipar el abandono o el éxito académico a partir de las características disponibles. Dado que se trata de un problema multiclase, deberás elegir métricas adecuadas para evaluar el rendimiento de tus modelos y justificar tu elección.

2.2. Tarea 2: Regresión

La segunda tarea consiste en construir un modelo de **regresión supervisada** para predecir la variable:

`unidades_curriculares_2do_semestre_calificacion`

que representa la calificación media obtenida por el estudiante en el segundo semestre.

Esta tarea debe formularse de forma metodológicamente correcta. En particular, deberás evitar el uso de variables que introduzcan **contaminación de los datos** (fuga de información, *data leakage*) respecto

al target. Por tanto, **no deberán utilizarse como predictores aquellas variables del segundo semestre cuya información sea contemporánea o prácticamente equivalente a la propia nota que se desea predecir**. En la memoria deberás justificar con claridad qué variables has excluido por este motivo y por qué.

El objetivo no es solo obtener una predicción precisa, sino también estudiar si es posible anticipar el rendimiento del segundo semestre a partir de información previa del estudiante, como sus características de entrada, su contexto socioeconómico y su desempeño en el primer semestre.

2.3. Tarea 3: Aprendizaje no supervisado

La tercera tarea consistirá en aplicar técnicas de **aprendizaje no supervisado** sobre un subconjunto razonado de variables. Puedes emplear, por ejemplo, clustering, PCA, métodos de visualización o cualquier otra técnica no supervisada que consideres adecuada.

El objetivo será identificar perfiles de estudiantes, patrones latentes o estructuras relevantes en los datos. No se trata necesariamente de recuperar exactamente las clases de la variable objetivo, sino de descubrir agrupaciones o relaciones que aporten información útil para interpretar mejor el fenómeno del abandono y del éxito académico.

3. Qué esperamos de tu trabajo

No solo queremos que construyas modelos con buen rendimiento predictivo, sino que extraigas conclusiones útiles y bien argumentadas sobre los factores que influyen en la trayectoria académica del alumnado. Algunas preguntas que puedes plantearte son las siguientes¹:

- ¿Qué variables están más asociadas con el abandono?
- ¿Qué factores parecen relacionarse con un mejor rendimiento académico en el segundo semestre?
- ¿Existen perfiles de estudiantes con características claramente diferenciadas?
- ¿Hay variables sobre las que una institución educativa podría actuar para mejorar los resultados?

Recuerda que **correlación no implica causalidad**. Cualquier conclusión debe ir acompañada de un análisis crítico y prudente. Queremos que plantees este proyecto como si fuera un proceso de modelización orientado a informar la toma de decisiones en una institución educativa, siendo consciente del impacto potencial de tus conclusiones.

4. Exploración adicional

Aunque las tres tareas anteriores constituyen el núcleo del proyecto, queremos que uses tu creatividad para enriquecer el trabajo. Algunas posibilidades son:

- comparar modelos lineales y no lineales;
- estudiar interpretabilidad mediante importancia de variables, permutation importance o SHAP;

¹Ojo: Estas preguntas solo son sugerencias, puedes (y debes) plantearte las tuyas propias, surgidas del análisis y la modelización de los datos.

- analizar el efecto de desbalanceo de clases en la clasificación;
- comparar distintas selecciones de variables para la regresión;
- evaluar la estabilidad de los clusters obtenidos en la parte no supervisada.

Si logras extraer conclusiones interesantes y bien defendidos, estos enriquecerán notablemente el proyecto.

5. Entrega y evaluación

Deberás entregar una memoria del proyecto, los ficheros con las predicciones solicitadas y un archivo comprimido con todo el código necesario para reproducir tus resultados.

5.1. Informe

Esperamos de ti un informe claro y bien estructurado que incluya, como mínimo:

1. **Exploración inicial y análisis descriptivo del conjunto de datos (EDA).**
2. **Preprocesado** realizado y decisiones metodológicas adoptadas.
3. **Implementación y evaluación** de la tarea de **clasificación**.
4. **Implementación y evaluación** de la tarea de **regresión**.
5. **Análisis** de la parte **no supervisada**.
6. **Interpretación crítica de los resultados**.
7. **Conclusiones finales** y posibles **limitaciones** del estudio.

Se valorará especialmente que el informe combine rigor técnico con claridad expositiva. No basta con mostrar métricas: debes interpretar los resultados y justificar tus decisiones. Tu informe debe tener una longitud igual o inferior a **8 páginas** en formato NeurIPS. Te recomendamos hacerlo en $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ usando la plantilla proporcionada por NeurIPS, aunque puedes utilizar otro editor siempre que respetes el formato. La bibliografía no cuenta para la longitud del documento.

5.2. Código desarrollado

Para el código que desarrolles deberás entregar un archivo comprimido en formato `.zip` o `.7z` que contenga todos tus scripts, notebooks y cualquier archivo adicional que consideres relevante adjuntar.

Dentro de esta carpeta comprimida es **imprescindible** incluir un archivo `README.md` con instrucciones claras y detalladas para reproducir los resultados del informe. Asegúrate de que cualquier persona con los datos y el código pueda seguir tus pasos y obtener los mismos resultados.

Se valorará positivamente que el código esté bien estructurado, documentado y organizado. Un código desordenado, ineficiente o poco claro podrá afectar negativamente a la calificación final.

Dale una vuelta:

Un buen proyecto no es necesariamente el que obtiene la mejor métrica absoluta, sino el que plantea un problema de forma correcta, construye una metodología coherente y extrae conclusiones sólidas y honestas a partir de los datos.