

Predicción del éxito académico en educación superior

Miguel Pajuelo Gómez
Ingeniería Matemática e Inteligencia Artificial

Curso 2025/2026

Abstract

Este trabajo analiza trayectorias académicas en educación superior a partir de información demográfica, socioeconómica, administrativa, macroeconómica y de rendimiento. El proyecto se formula como tres tareas conectadas: clasificación de la situación final del estudiante, regresión de la calificación media del segundo semestre y análisis no supervisado de perfiles. La parte central del trabajo no consiste únicamente en aplicar modelos, sino en convertir un dataset heterogéneo en una representación numérica coherente y en implementar manualmente varios algoritmos supervisados. En particular, se programaron desde cero el preprocesado de variables, Linear Discriminant Analysis, un árbol de regresión y un Gradient Boosting Regressor. Los resultados muestran que las variables académicas tempranas, sobre todo la ratio de éxito del primer semestre, son las señales más informativas. Las conclusiones se presentan como asociaciones predictivas útiles para apoyo institucional, no como relaciones causales.

1. Introducción

El objetivo oficial del proyecto es construir modelos predictivos que permitan estudiar la trayectoria académica de estudiantes universitarios. El dataset distingue tres estados finales: abandono, permanencia como matriculado y graduación. A partir de esa información se plantean tres preguntas complementarias. Primero, si es posible clasificar la situación final del estudiante. Segundo, si puede anticiparse la calificación media del segundo semestre sin introducir fuga de información. Tercero, si existen perfiles latentes de estudiantes que ayuden a interpretar el fenómeno más allá de la etiqueta final.

Estas tareas tienen una lectura institucional. Una universidad no necesita solamente una métrica alta, sino señales interpretables que permitan detectar riesgo académico, diseñar acompañamiento y revisar posibles barreras administrativas. Por esa razón, el informe no separa de forma artificial predicción e interpretación: las decisiones de preprocesado, la elección de modelos y la discusión de resultados se evalúan en función de si producen conclusiones defendibles y metodológicamente prudentes.

El trabajo combina librerías estándar para partición, métricas, PCA y K-Means con implementaciones propias en los modelos supervisados. Esta decisión tiene valor técnico dentro del proyecto: obliga a explicitar cómo se calculan las matrices de dispersión en LDA, cómo se escoge un split en un árbol de regresión y cómo el boosting ajusta sucesivamente residuos. Frente a usar directamente una clase de una librería, construir estos componentes desde cero permite conectar con más claridad la formulación matemática, el código y los resultados finales.

2. Datos, investigación inicial y preprocesado

El archivo original `rendimiento_estudiantes.csv` contiene 4424 observaciones, 37 columnas y ningún valor faltante. Antes de modelar se realizó una fase de inspección para entender el significado de las variables y evitar transformaciones automáticas poco justificadas. El dataset mezcla variables binarias, ordinales, nominales de alta cardinalidad, magnitudes continuas y conteos académicos de dos semestres. Además, algunas variables del segundo semestre son casi equivalentes al objetivo de regresión, por lo que no podían tratarse como predictores sin más.

Cuadro 1: Resumen operativo del dataset y de las tareas.

Elemento	Descripción
Distribución de clases	Abandono: 1421 (32.12 %), Graduado: 2209 (49.93 %), Matriculado: 794 (17.95 %)
Bloques de variables	Perfil personal, acceso académico, administración, economía, rendimiento de primer y segundo semestre
Dataset procesado	4424 × 63 tras codificación manual, agrupación de categorías, ratios y normalización
Clasificación	Target: <code>objetivo</code> ; modelo propio: LDA; split 80/20; oversampling solo en entrenamiento
Regresión	Target: <code>nota_media_2sem</code> ; modelo propio: Gradient Boosting; exclusión de variables con leakage
No supervisado	PCA y K-Means sobre predictores estandarizados; selección de k mediante silhouette

La exploración inicial permitió organizar las columnas en bloques con semántica distinta. Las variables demográficas describen edad, género, nacionalidad, desplazamiento e internacionalización. Las variables de acceso recogen el modo de solicitud, el orden de preferencia, el curso, la cualificación previa y las notas de admisión. Las variables administrativas y socioeconómicas incluyen beca, deuda, matrícula al día y necesidades educativas especiales. Por último, las variables académicas resumen asignaturas matriculadas, evaluadas, aprobadas, sin evaluación y calificaciones medias en ambos semestres. Esta separación fue importante porque no todas las columnas tienen el mismo papel metodológico: algunas son información previa, otras son indicadores administrativos, y otras describen rendimiento ya observado.

El preprocesado se implementó manualmente en dos scripts auxiliares: uno organiza el flujo de carga, revisión y guardado, y otro concentra los mapeos y transformaciones. No se aplicó una codificación genérica a todo el dataset; cada familia de variables se transformó según su significado. Las variables binarias, como `becado`, `deudor`, `desplazado`, `internacional`, `matricula_al_dia` o `genero`, se mapearon explícitamente a 0/1. Las variables ordinales de cualificación se convirtieron a escalas educativas ordenadas, preservando que un nivel formativo superior representa una posición distinta en la escala. En cambio, las variables nominales sin orden natural se agruparon antes de usar one-hot encoding.

Esa agrupación fue una parte relevante del trabajo propio. El modo de solicitud se redujo a categorías interpretables, como contingente general, cambio o traslado, estudiante internacional, mayor de 23 años, titulación previa o vía legal. Las carreras se agruparon por áreas, por ejemplo salud, gestión, tecnología e ingeniería, servicio social o turismo. Las ocupaciones de los padres se reorganizaron por sectores profesionales: dirección y gestión, profesionales cualificados, técnicos intermedios, servicios y ventas, industria y transporte, agricultura o situaciones sin actividad/no informadas.

Las variables académicas requerían un tratamiento específico. Los conteos de asignaturas matriculadas, evaluadas, aprobadas y sin evaluación están fuertemente relacionados entre sí. Para reducir esa colinealidad se construyeron dos ratios por semestre:

$$\text{ratio_presentacion} = \frac{\text{evaluadas}}{\text{matriculadas}}, \quad \text{ratio_exito} = \frac{\text{aprobadas}}{\text{evaluadas}}.$$

Después se eliminan las columnas originales redundantes y también las asignaturas convalidadas, que no aportaban una señal clara al planteamiento final. El resultado es una representación más compacta: conserva información académica interpretable y reduce dependencias mecánicas entre predictores.

Finalmente, se normalizaron las columnas numéricas a $[0,1]$ y se guardó `rendimiento_estudiantes_procesado.csv`. Esta normalización hace que LDA, PCA y K-Means no queden dominados por variables con escala mayor. Como limitación, el script calcula los parámetros de normalización antes del split train/test; para un despliegue real debería ajustarse el escalado únicamente sobre entrenamiento y aplicarse después al test.

3. Metodología e implementación

La metodología se diseñó para que cada tarea respondiera a una pregunta distinta, pero usando una base de datos procesada común. En clasificación se busca separar los tres estados finales. En regresión se quiere estudiar la viabilidad de predecir `unidades_curriculares_2do_semestre_calificacion`, renombrada en el CSV procesado como `nota_media_2sem`, eliminando variables que revelarían información del segundo semestre. En la parte no supervisada se buscan patrones en los datos para identificar perfiles latentes de estudiantes, sin utilizar directamente la etiqueta final.

3.1. Modelos implementados desde cero

Una parte importante del proyecto fue la programación manual de varios componentes. En `lda.py` se implementó Linear Discriminant Analysis. El código calcula medias por clase, media global, matriz de dispersión intraclass S_W , matriz de dispersión entre clases S_B , pseudoinversa de S_W y autovectores discriminantes. Con tres clases, la proyección queda limitada a dos componentes, lo que permite interpretar los pesos de cada variable y no solo obtener predicciones. La predicción se realiza proyectando cada muestra al espacio LDA y asignando la clase con mayor score:

$$s_c(x) = -\frac{1}{2} \|W^\top x - W^\top \mu_c\|^2 + \log \pi_c.$$

En `boosting.py` se implementaron dos piezas conectadas. Primero, un árbol de regresión que construye recursivamente nodos de decisión. Para cada variable se prueban umbrales candidatos y se elige el split que maximiza la reducción de impureza, medida como reducción de varianza. El árbol se detiene por profundidad máxima, tamaño mínimo de nodo o ausencia de mejora válida, y cada hoja predice la media del target residual. Segundo, se implementó un Gradient Boosting Regressor que inicializa la predicción con la media de y y entrena árboles sucesivos sobre los residuos:

$$\hat{y}^{(0)} = \bar{y}, \quad r_i^{(t)} = y_i - \hat{y}_i^{(t-1)}, \quad \hat{y}^{(t)} = \hat{y}^{(t-1)} + \eta h_t(x_i).$$

También se programó el cálculo de importancias acumulando la reducción de impureza de los splits usados por los árboles del ensemble.

Estas implementaciones no sustituyen a una librería optimizada en términos de eficiencia, pero sí aportan transparencia. Al construir manualmente LDA, árbol y boosting, el experimento deja de ser una llamada opaca a una librería: se sabe qué hipótesis utiliza el modelo, cómo se calcula cada predicción y de dónde salen los pesos o importancias que luego se interpretan. En los experimentos finales se usan precisamente estas clases propias para LDA y Gradient Boosting; las librerías externas se reservan para utilidades auxiliares como partición, métricas, PCA, K-Means y visualización.

3.2. Diseño experimental

En clasificación se usa un split 80/20 con `random_state=0`. Dado el desbalanceo de clases, se aplica oversampling únicamente al conjunto de entrenamiento mediante duplicación de la clase minoritaria. Las clases de entrenamiento pasan de (1137, 1759, 643) a (1137, 1759, 1286) para abandono, graduado y matriculado respectivamente. El test permanece intacto con (284, 450, 151), porque debe representar una evaluación realista.

En regresión, el target es `nota_media_2sem`. Para evitar contaminación se eliminan `nota_media_2sem`, `ratio_presentacion_2sem`, `ratio_exito_2sem` y `objetivo`. Los dos ratios del segundo semestre se excluyen porque dependen de información contemporánea al target; la etiqueta final también se excluye porque no estaría disponible si el objetivo es anticipar rendimiento. Se aplicó validación cruzada de 3 particiones para encontrar los parámetros óptimos entre distintas combinaciones de número de estimadores y profundidad; la configuración final usada en el informe es 40 árboles, profundidad máxima 3 y learning rate 0.1.

En aprendizaje no supervisado se estandarizan los predictores con media cero y desviación típica uno. PCA se usa para estudiar la dimensionalidad y proyectar los datos; K-Means se evalúa para $k = 2, \dots, 8$ con 20 inicializaciones. En la revisión final se regeneró esta parte de forma consistente sobre el espacio estandarizado, corrigiendo una inconsistencia del notebook original donde algunas proyecciones PCA se calcularon sobre datos sin estandarizar.

4. Resultados

4.1. Clasificación y regresión

La Figura 1 resume los resultados supervisados. LDA alcanza una accuracy de 0.716. La matriz de confusión muestra que el modelo reconoce muy bien a los graduados (423/450) y de forma razonable los abandonos (174/284), pero tiene dificultades con la clase matriculado (37/151). El error más frecuente consiste en clasificar estudiantes matriculados como graduados (94 casos), lo que sugiere que la clase intermedia se solapa con trayectorias académicas que el modelo interpreta como éxito final.




Figura 1: Resultados supervisados con los modelos implementados: matriz de confusión del LDA propio, variables con mayor peso discriminante, predicciones del Gradient Boosting propio y variables más importantes en la regresión.

La interpretación de los pesos de LDA es coherente con el problema. Las variables con mayor contribución son `ratio_exito_2sem`, `ratio_exito_1sem`, `matricula_al_dia`, `nota_media_2sem`, `becado` y las ratios de presentación. En otras palabras, la separación entre abandono, graduación y permanencia se explica sobre todo por rendimiento observado y regularidad académica-administrativa. Esta lectura debe hacerse con cuidado: al incluir variables del segundo semestre, la clasificación describe bien la situación final, pero no equivale a una alerta temprana construida únicamente con información de entrada.

En regresión, el Gradient Boosting implementado obtiene RMSE 0.128 y $R^2 = 0.796$ en escala normalizada. La nube real-predicho se concentra cerca de la diagonal para calificaciones medias y altas, mientras que los valores cercanos a cero muestran más dispersión. Esto indica que el modelo captura patrones generales de rendimiento, pero tiene más dificultad para anticipar casos extremos de fracaso académico.

Las importancias del ensemble refuerzan la conclusión principal. La variable dominante es `ratio_exito_1sem`, con un 31.1 % de la importancia total. A continuación aparecen `nota_admision`, `ratio_presentacion_1sem`, `nota_media_1sem`, `orden_solicitud` y variables de cualificación. La predicción de la nota del segundo semestre depende principalmente de señales académicas tempranas: aprobar una mayor proporción de asignaturas, presentarse a las evaluaciones y obtener buenas calificaciones iniciales resume adaptación, hábitos de estudio y

dominio de contenidos.

4.2. PCA y clustering

El análisis PCA muestra que la información no está concentrada en pocas dimensiones. Se necesitan 42 componentes para explicar el 90 % de la varianza y 48 para el 95 %. Por tanto, la proyección PC1-PC2 debe entenderse como una herramienta de visualización parcial, no como una descripción completa del dataset.




Figura 2: Análisis no supervisado regenerado sobre predictores estandarizados: varianza acumulada de PCA, selección de k por silhouette y visualización de los clusters de K-Means en el plano de las dos primeras componentes.

Con K-Means sobre el espacio estandarizado, el mayor silhouette en $k = 2, \dots, 8$ se obtiene para $k = 4$ (0.129). El valor absoluto es bajo, de modo que no hay grupos perfectamente separados; aun así, los perfiles resultantes son interpretables y ayudan a resumir patrones del alumnado. La Tabla 2 muestra medias normalizadas o proporciones para variables binarias.

Cuadro 2: Perfil medio de los clusters seleccionados por silhouette ($k = 4$).

Cluster	n	Éxito 1sem	Nota 2sem	Mayor 23	Internacional	Matrícula día	Interpretación
C0	110	0.565	0.553	0.100	1.000	0.791	Perfil internacional, rendimiento medio
C1	811	0.452	0.508	0.713	0.000	0.772	Acceso no tradicional y más vespertino
C2	2903	0.695	0.673	0.026	0.000	0.945	Contingente general, rendimiento alto
C3	600	0.018	0.018	0.202	0.000	0.735	Bajo rendimiento y riesgo académico

El cluster C2 es el perfil más estable: agrupa a la mayoría de estudiantes, con alta proporción de contingente general, matrícula al día y buen rendimiento en ambos semestres. C3 concentra el riesgo académico más claro, con ratios de éxito y notas prácticamente nulas. C1 recoge un perfil no tradicional, con alta presencia de acceso por mayores de 23 años y mayor peso de asistencia vespertina. C0 es pequeño y está definido por la condición internacional. Estos clusters no pretenden recuperar las clases objetivo; ofrecen una segmentación exploratoria que complementa la clasificación supervisada.

5. Discusión

Los tres bloques convergen en una conclusión clara: la trayectoria académica temprana es la señal más informativa del éxito posterior. En clasificación, los pesos discriminantes se concentran en ratios de éxito, notas y matrícula al día. En regresión, la ratio de éxito del primer semestre domina la importancia de variables. En clustering, los perfiles más claros también se ordenan por rendimiento y regularidad administrativa. La coherencia entre tareas refuerza la interpretación, porque la misma familia de variables aparece como relevante con enfoques distintos.

Desde una perspectiva institucional, estas señales son útiles si se interpretan con prudencia. Una universidad no puede actuar sobre edad, nacionalidad o trayectoria familiar, pero sí puede detectar bajo rendimiento temprano, baja presentación a evaluaciones, incidencias administrativas o problemas de matrícula. Los modelos podrían apoyar tutorías, seguimiento académico y revisión de barreras burocráticas, siempre con supervisión humana y sin convertir la predicción en una etiqueta rígida.

El estudio también tiene limitaciones. La primera es causal: los modelos detectan asociaciones, no efectos. La segunda es el desbalanceo, que afecta especialmente a la clase matriculado y hace que la accuracy sea insuficiente por sí sola. La tercera es metodológica: la normalización global del preprocesado introduce una posible fuga menor de escala. La cuarta afecta a la interpretación temporal: la clasificación incluye variables del segundo semestre, por lo que no debe presentarse como predicción temprana pura. Por último, los clusters tienen silhouette bajo y deben entenderse como perfiles solapados, no como segmentos naturales perfectamente separados.

6. Conclusiones

El proyecto cumple las tres tareas exigidas y muestra una relación clara entre preprocesado, modelos y resultados. La construcción manual del dataset procesado permitió transformar información heterogénea en variables numéricas interpretables. Las implementaciones propias de LDA, árbol de regresión y Gradient Boosting conectan la teoría con el código y hacen más transparente la interpretación de pesos, scores e importancias.

En clasificación, LDA ofrece una solución compacta e interpretable, con buen reconocimiento de graduados pero limitaciones sobre la clase matriculado. En regresión, el Gradient Boosting propio predice la nota del segundo semestre con buen ajuste relativo (RMSE 0.128, $R^2 = 0.796$), apoyándose principalmente en el rendimiento del primer semestre. En aprendizaje no supervisado, PCA revela alta dimensionalidad y K-Means identifica perfiles útiles, especialmente un grupo de rendimiento alto y otro de riesgo académico extremo.

La conclusión final es moderada: los datos contienen señales tempranas valiosas para orientar seguimiento académico, pero no justifican decisiones automáticas ni afirmaciones causales. El valor del proyecto está en una metodología reproducible, técnicamente transparente y capaz de convertir datos educativos complejos en evidencia útil para la toma de decisiones.

Referencias

- [1] Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- [2] Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*. Springer.
- [3] James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning*. Springer.